Zaawansowana Ekonometria

Paweł Struski

Uniwersytet Warszawski

16 marca 2026

Plan na dzisiaj

- Stacjonarność (ang. *stationarity*)
- Autokorelacja (autocorrelation/serial correlation).

Stacjonarność (stationarity)

Definicja: Stacjonarność (stationarity)

Proces stochastyczny $\{y_t : t = 1, 2, 3 \ldots\}$ nazywamy stacjonarnym, jeżeli dla każdego zbioru indeksów czasu $t_1, t_2, \ldots, t_m$ oraz każdej liczby naturalnej $k \geq 1$ łączny rozkład prawdopodobieństwa zmiennych $(y_{t_1}, y_{t_2}, y_{t_3}, \ldots, y_{t_m})$ jest taki sam jak łączny rozkład prawdopodobieństwa zmiennych $(y_{t_1+k}, y_{t_2+k}, y_{t_3+k}, \ldots, y_{t_m+k})$.

Intuicja: Łączny rozkład prawdopodobieństwa zmiennych x jest **stały w czasie**.

W przeciwnym wypadku, proces nazywamy niestacjonarnym.

Stacjonarność kowariancyjna (covariance stationarity)

Definicja: Stacjonarność kowariancyjna / słaba

Proces stochastyczny $\{y_t : t = 1, 2, 3 \ldots\}$ nazywamy stacjonarnym kowariancyjnie (słabo stacjonarnym), jeżeli jego pierwszy i drugi moment są stałe w czasie tzn.:

1. $\mathrm{E}[y_t]$ nie zależy od czasu t
2. $\mathrm{Var}(y_t)$ nie zależy od czasu t
3. $\mathrm{Cov}(y_t,\, y_{t+k})$ nie zależy od czasu t $\quad \forall\, t,\ \forall\, k \geq 1$

Uwaga: Stacjonarność ścisła $\Rightarrow$ stacjonarność kowariancyjna (przy skończonych drugich momentach), ale implikacja odwrotna **nie** zachodzi w ogólności.

Przykład 1

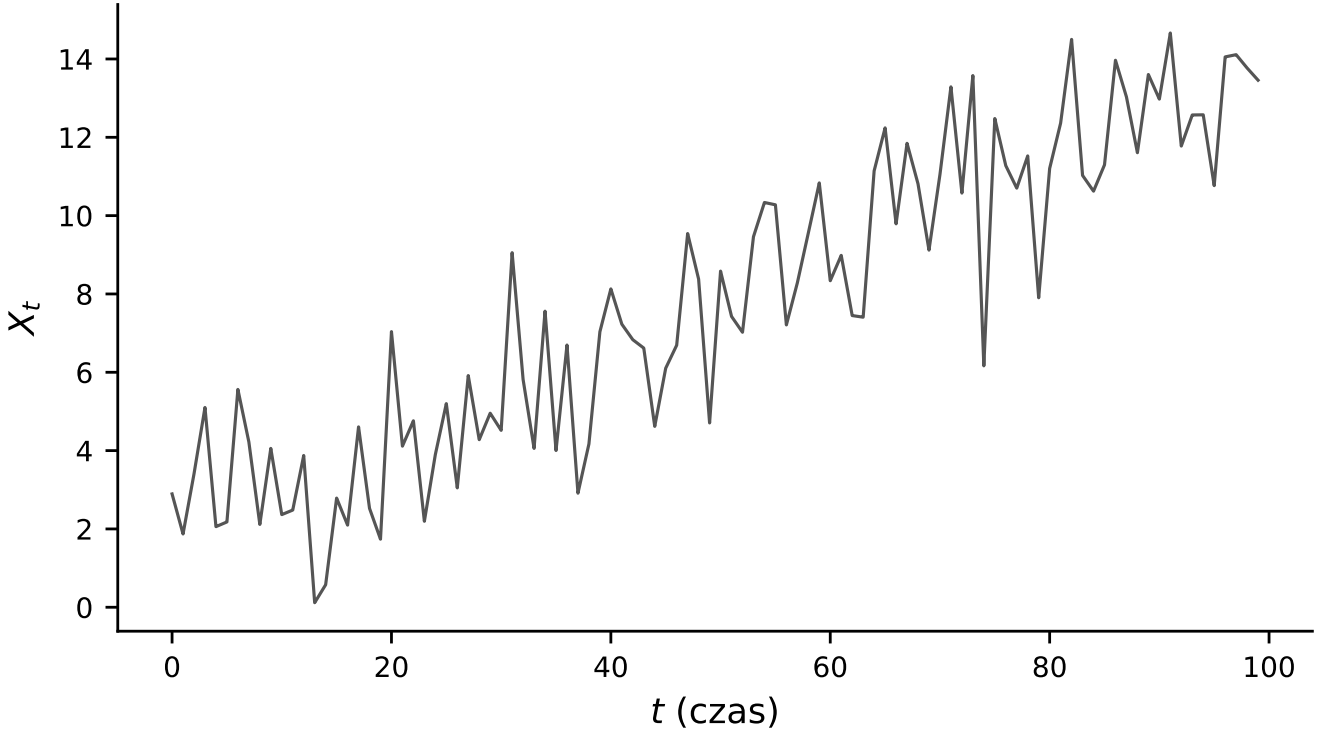

Czy ten szereg jest stacjonarny?

Przykład 1

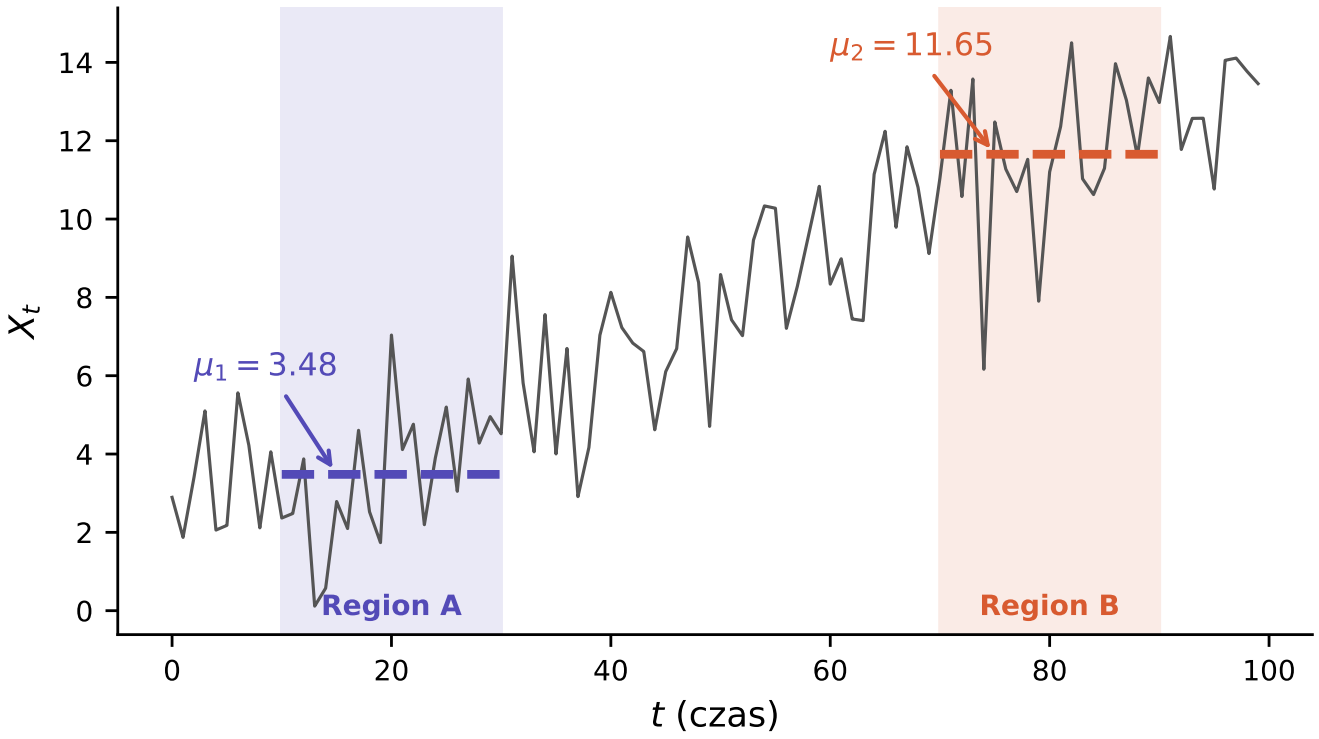

Średnie w obu regionach są różne: $\mu_1 \approx 3{,}48$ vs. $\mu_2 \approx 11{,}65$

$\mathrm{E}[x_t]$ zależy od t $\implies$ warunek (1) stacjonarności kowariancyjnej jest złamany $\implies$ szereg jest **niestacjonarny**.

Przykład 2

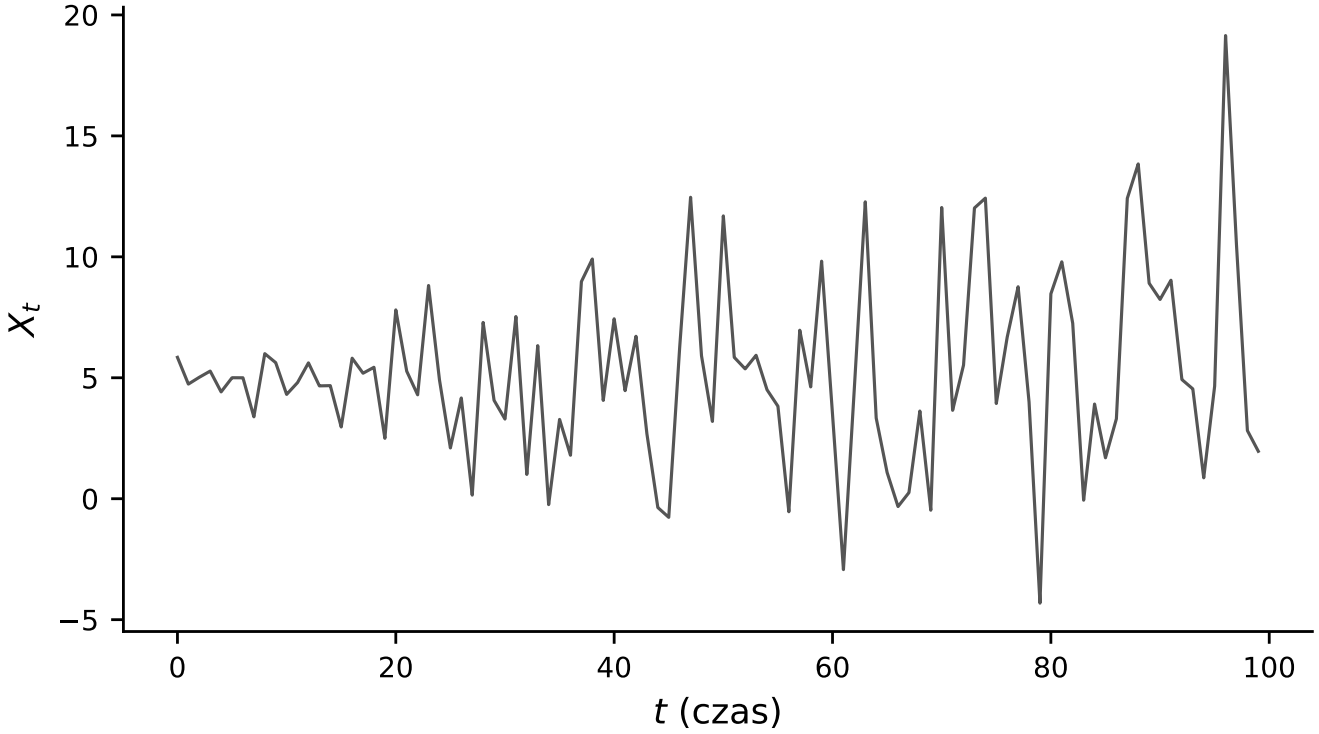

Czy ten szereg jest stacjonarny?

Przykład 2

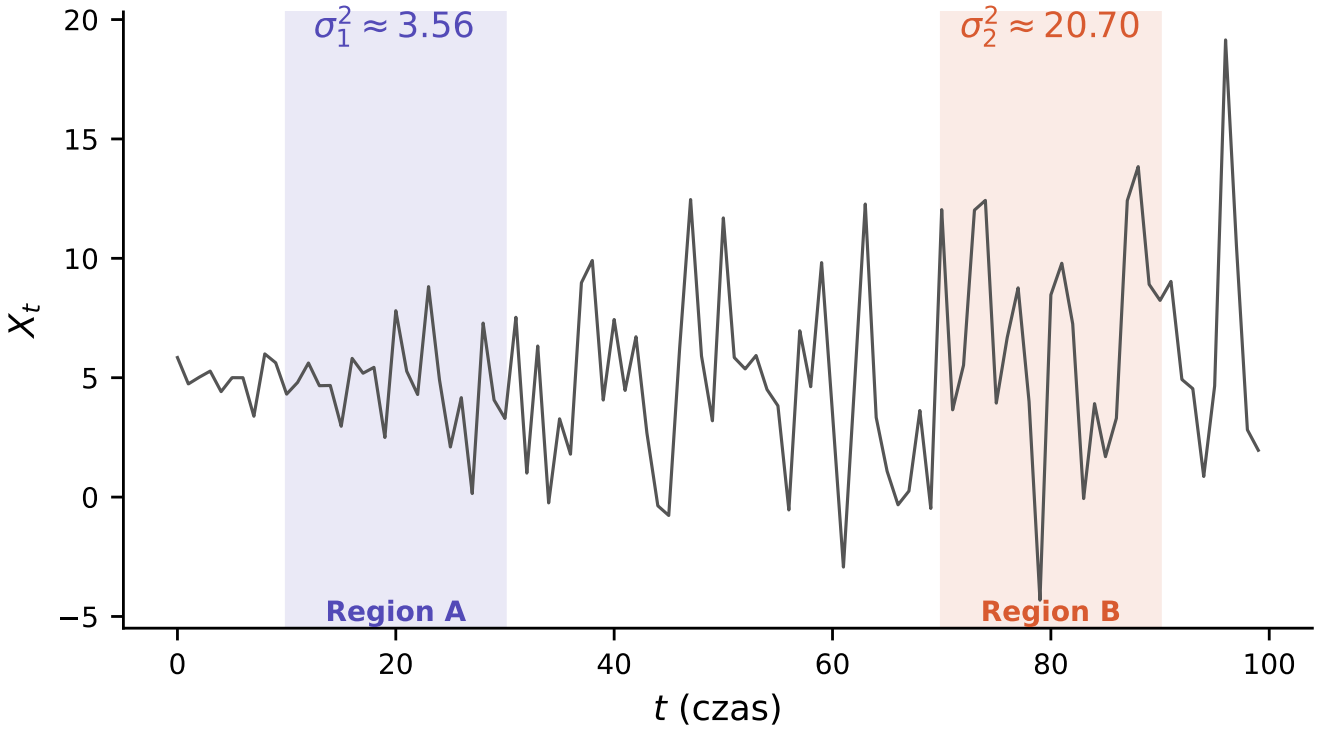

Wariancje w obu regionach są różne: $\sigma_1 \approx 3{,}56$ vs. $\sigma_2 \approx 20{,}70$

$\mathrm{Var}[x_t]$ zależy od t $\Longrightarrow$ warunek (2) stacjonarności kowariancyjnej jest złamany $\Longrightarrow$ szereg jest **niestacjonarny**.

Przykład 3

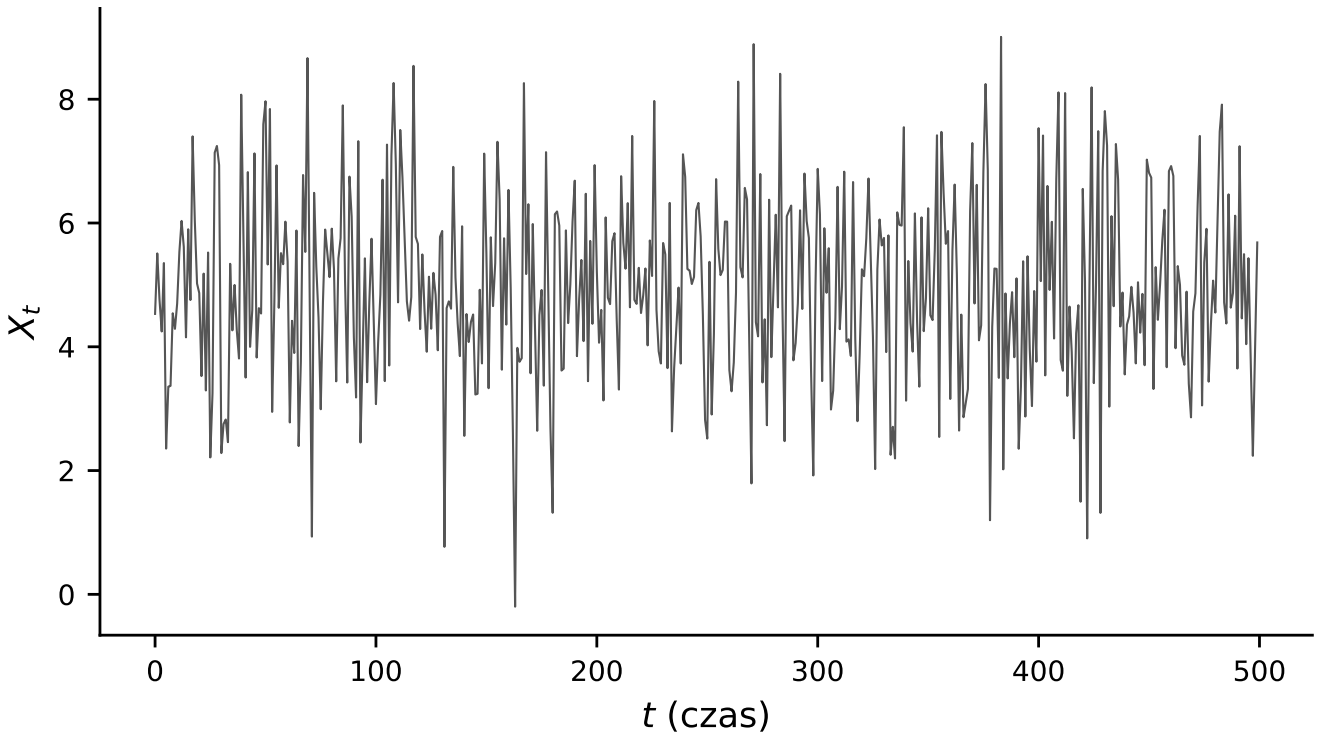

Czy ten szereg jest stacjonarny?

Przykład 3

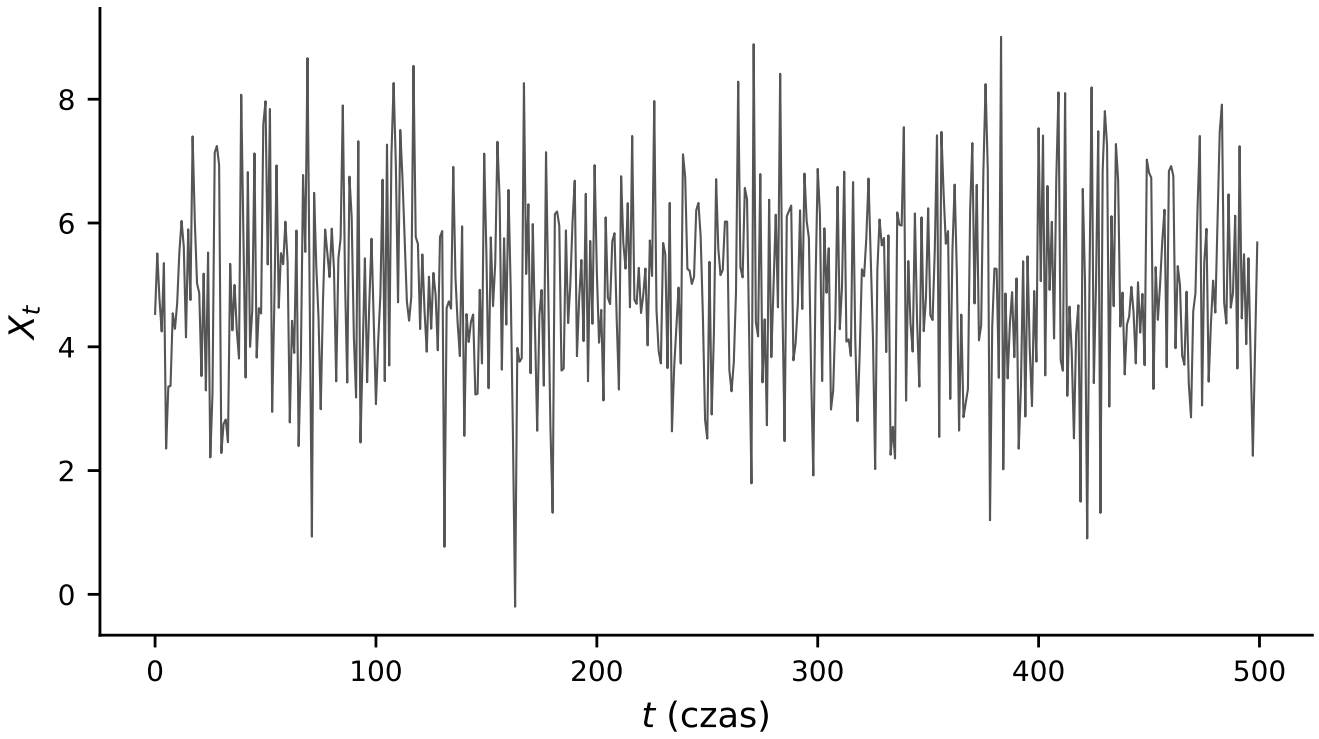

Czy ten szereg jest stacjonarny?

Tak. Szereg oscyluje stabilnie wokół jednej średniej ze stała wariancją.

Zadanie 1

Przeprowadzono test Dickey-Fuller'a. Czy na podstawie tego testu możemy stwierdzić, że testowana zmienna jest stacjonarna? Uzasadnij odpowiedź.

```
Dickey-Fuller test for unit root                   Number of obs   = 40
Variable: diff_inv                                 Number of lags =  0

H0: Random walk without drift, d = 0

                                          Dickey-Fuller
                  Test      ---------- critical value ----------
              statistic           1%           5%          10%
--------------------------------------------------------------
 Z(t)            -5.189       -3.648       -2.958       -2.612
--------------------------------------------------------------
MacKinnon approximate p-value for Z(t) = 0.0000.
```

Zadanie 2

Mamy następujący model: $y_t = \alpha + y_{t-1} + \epsilon_t$ gdzie $\epsilon_t \sim IID(0, \sigma^2)$

Pokaż, że zmienna $y_t \sim I(1)$ tzn. jest zintegrowana rzędu 1.

Zadanie 3

Mamy y_t dane następującym procesem AR(1):

$y_t = \alpha\, y_{t-1} + \varepsilon_t, \quad |\alpha| < 1, \quad$ gdzie $\quad \varepsilon_t = u_t + \rho\, u_{t-1}\,,$

$\mathrm{Var}(u_t) = \sigma^2, \quad \mathrm{Cov}(u_t, u_s) = 0$ dla $t \neq s, \quad |\rho| < 1.$

Polecenia:

1. Zapisz y_t jako nieskończoną sumę zależną wyłącznie od $u_t, u_{t-1}, u_{t-2}, \ldots$
2. Obliczć $\mathrm{Var}(y_t)$.
3. Czy estymator MNK (OLS) parametru α jest zgodny? Uzasadnij, obliczając $\mathrm{Cov}(y_{t-1}, \varepsilon_t)$.

Wnioski: rola ρ w modelu AR(1)

Model: $y_t = \alpha\, y_{t-1} + \varepsilon_t, \quad \varepsilon_t = u_t + \rho\, u_{t-1}$

Przypadek $\rho = 0$ (brak autokorelacji błędu)

- $\varepsilon_t = u_t$ (biały szum)
- $\mathrm{Cov}(y_{t-1}, \varepsilon_t) = 0$
- OLS: obciążony w skończonej próbie, ale **zgodny**

Przypadek $\rho \neq 0$ (autokorelacja błędu)

- ε_t zawiera u_{t-1}, a y_{t-1} też zależy od u_{t-1}
- $\mathrm{Cov}(y_{t-1}, \varepsilon_t) = \rho\,\sigma^2 \neq 0$ –> **endogeniczność** (czasem może występować pod nazwą "równoczesność"/"symultaniczność")
- OLS jest **obciążony i niezgodny**

Morał: opóźniona zmienna zależna + autokorelacja błędu = endogeniczność

Stacjonarność a autokorelacja błędu w modelu AR(1)

Model: $y_t = \alpha\, y_{t-1} + \varepsilon_t$

	Brak autokorelacji błędu $\varepsilon_t = u_t$	**Autokorelacja błędu** $\varepsilon_t = u_t + \rho\, u_{t-1}$
Stacjonarny $\lvert\alpha\rvert < 1$	**OK** OLS spójny std. wnioskowanie działa	**Endogeniczność** $\mathrm{Cov}(y_{t-1}, \varepsilon_t) \neq 0$ OLS niespójny
Niestacjonarny $\alpha = 1$	**Pierwiastek jedn.** regresja pozorna niestd. rozkłady	**Oba problemy** regresja pozorna + endogeniczność

*Wniosek: stacjonarność ($|\alpha| < 1$) jest **konieczna**, ale **nie wystarczająca**. Trzeba również sprawdzić strukturę błędu losowego.*

Podsumowanie

- Powtórzyliśmy definicje stacjonarności.
- Pokazaliśmy jak można sprawdzać stacjonarność wizualnie, testem DF oraz algebraicznie w prostym przypadku.
- Pokazaliśmy, że autokorelacja błędu losowego w modelu AR(1) prowadzi do problemu endogeniczności (zadanie 3).