Zaawansowana Ekonometria

Paweł Struski

Uniwersytet Warszawski

27 kwietnia 2026

Plan na dzisiaj

- Zmienne binarne
- Model probit i logit

Dlaczego nie regresja liniowa?

Chcemy modelować $\Pr(y_i = 1 \mid x_i)$. Liniowy Model Prawdopodobieństwa (LPM):

$$\Pr(y_i = 1 \mid x_i) = x_i\beta$$

Problemy:

- Wartości dopasowane mogą wyjść **poza** $[0, 1]$
- **Heteroskedastyczność**: $\mathrm{Var}(y_i \mid x_i) = p_i(1 - p_i)$ zależy od x_i

Rozwiązanie: "przepuścić" $x_i\beta$ przez nieliniową funkcję, która daje wartości w $(0, 1)$:

$$\Pr(y_i = 1 \mid x_i) = F(x_i\beta)$$

- $F = \Phi$ (dystrybuanta normalna) $\rightarrow$ **probit**
- $F = \Lambda$ (dystrybuanta logistyczna) $\rightarrow$ **logit**

Probit vs logit

Probit: $\Pr(y_i = 1 \mid x_i) = \Phi(x_i\beta)$

Logit: $\Pr(y_i = 1 \mid x_i) = \Lambda(x_i\beta) = \dfrac{\exp(x_i\beta)}{1 + \exp(x_i\beta)}$

W praktyce dają bardzo zbliżone wyniki. Główna różnica to interpretacja współczynników. Współczynniki modelu logit mają naturalną interpretację jako logarytm ilorazu szans (Odds Ratio).

Efekty cząstkowe i ilorazy szans

Aby uzyskać wpływ danej zmiennej w modelu na prawdopodobieństwo zmiennej objaśnianej musimy policzyć $\rightarrow$ **efekty cząstkowe**.

Efekt cząstkowy – o ile zmienia się $\Pr(y=1)$ gdy x_k wzrasta o jednostkę:

$$\frac{\partial \Pr(y=1 \mid x)}{\partial x_k} = f(x\beta) \cdot \beta_k$$

gdzie f to gęstość odpowiedniego rozkładu. Zależy od **punktu** x – zwykle liczymy dla średnich.

Testowanie w modelach MNW

Test ilorazu wiarogodności (LR) – porównujemy model pełny z ograniczonym:

$$LR = 2\big(\ln L_{\text{pełny}} - \ln L_{\text{ograniczony}}\big) \ \sim \ \chi^2(r)$$

gdzie r = liczba nałożonych ograniczeń (wyrzuconych zmiennych).

Łączna istotność zmiennych: $\ln L_{\text{ograniczony}}$ = model z samą stałą.

Pseudo R^2 McFaddena:

$$R^2_{\text{McF}} = 1 - \frac{\ln L_{\text{pełny}}}{\ln L_{\text{stała}}}$$

Nie ma prostej interpretacji "% wyjaśnionej wariancji" – to miara poprawy dopasowania względem modelu z samą stałą.

Zadanie 1 – Model probitowy: dane

Model probitowy dla faktu posiadania pracy. Kodowanie: płeć (0 m, 1 k); pracowal (0/1).

$N = 48\,011$, Log likelihood $= -25\,355{,}75$, LR $\chi^2(3) = 14\,361{,}19$, $p = 0{,}000$,
Pseudo $R^2 = 0{,}2207$

	Coef.	**Std. Err.**	**z**	**P>|z|**
plec	−0,2990	0,0129	−23,16	0,000
wiek	0,2141	0,0023	92,16	0,000
wiek2	−0,0026	0,0000	−94,68	0,000
_cons	−3,7377	0,0450	−83,03	0,000

Efekty cząstkowe ($\hat{y} = 0{,}6776$):

	dy/dx	**Std. Err.**	**z**	**P>|z|**	$\bar{X}$
plec*	−0,1066	0,0046	−23,29	0,000	0,526
wiek	0,0768	0,0007	111,87	0,000	37,00
wiek2	−0,0009	0,0000	−118,19	0,000	1369

* dy/dx – dyskretna zmiana zmiennej 0-1

Zadanie 1 – Pytania

Testy na poziomie istotności $\alpha = 0{,}05$.

1. Wypisać założenia modelu probitowego.
2. Które założenie KMRL będzie najprawdopodobniej fałszywe dla modelu liniowego (LPM)?
3. Na jakie problemy natkniemy się szacując model za pomocą MNK?
4. Jakie wnioski z oszacowań parametrów?
5. Zinterpretować R^2 i statystykę LR. Czy zmienne łącznie istotne?
6. Zinterpretować efekt cząstkowy dla płci.
7. Policzyć efekt cząstkowy dla wieku (średni wiek: 37 lat).
8. Jaki model zbudować, by testować czy wiek wpływa inaczej na kobiety i mężczyzn? Jaki jest wynik tego testu jeśli dla tak rozbudowanego modelu maksimum logarytmu funkcji wiarygodności wynosi 25353.992

Podpowiedź: $\chi^2_{0,95}(1) = 3{,}84, \quad \chi^2_{0,95}(2) = 5{,}99, \quad \chi^2_{0,95}(3) = 7{,}81.$

Zadanie 2 – Model logitowy: dane

Model logitowy: p-stwo poszukiwania pracy ($N = 27\,501$, LR $\chi^2(2) = 2448{,}19$, Pseudo $R^2 = 0{,}0880$, Log likelihood $= -12\,678{,}788$). Kodowanie: SEX (0 m, 1 k); LOOK4WORK (0/1).

LOOK4WORK	**Coef.**	**Std. Err.**	**z**	**P> |z|**
SEX	−0,3568	0,0314	−11,37	0,000
AGE	−0,0342	0,0008	−44,17	0,000
_cons	0,2516	0,0359	7,01	0,000

Ilorazy szans:

	Odds Ratio	**Std. Err.**	**z**	**P> |z|**
SEX	0,6999	0,0220	−11,37	0,000
AGE	0,9663	0,0007	−44,17	0,000

Zadanie 2 – Pytania

Testy na poziomie istotności $\alpha = 0{,}05$.

1. Wypisać założenia modelu logitowego.
2. Sprawdzić łączną istotność zmiennych. Zinterpretować Pseudo R^2.
3. Które zmienne w modelu są istotne?
4. Czy relacje między ilorazami szans a wielkościami parametrów odpowiadają twoim oczekiwaniom?
5. Wartość funkcji gęstości dla $x\hat{\beta}$ wynosi 0,145. Policzyć krańcowy wpływ wieku na prawdopodobieństwo poszukiwania pracy.
6. Postanowiono sprawdzić hipotezę, że wykształcenie ma wpływ na prawdopodobieństwo poszukiwania pracy. Wartość funkcji wiarygodności w maksimum dla modelu logitowego ze zmiennymi objaśniającymi wiek, płeć i wykształcenie wyniosła -11052.407. Zweryfikuj hipotezę mówiącą o tym, że wykształcenie wpływa na prawdopodobieństwo poszukiwania pracy.

Podpowiedź: $\chi^2_{0,95}(7) = 14{,}07$, $\chi^2_{0,95}(8) = 15{,}51$, $\chi^2_{0,95}(9) = 16{,}91$, $\chi^2_{0,95}(10) = 18{,}31$.

Zadanie 3 – Wrażliwość i specyficzność

Oszacowano model logitowy przewidujący, czy klient sklepu internetowego dokona zwrotu zakupionego produktu ($y = 1$ – zwrot, $y = 0$ – brak zwrotu). Na próbie testowej ($N = 500$) uzyskano następujące tabele trafności dla trzech punktów odcięcia:

$p^* = 0{,}3$

	Zaobserw.	
Prognoza	1	0
1	108	85
0	12	295

$p^* = 0{,}5$

	Zaobserw.	
Prognoza	1	0
1	78	30
0	42	350

$p^* = 0{,}7$

	Zaobserw.	
Prognoza	1	0
1	36	6
0	84	374

Łącznie: 120 klientów zwróciło produkt, 380 nie zwróciło.

Polecenie: Policz wrażliwość i specyficzność modelu dla każdego z trzech punktów odcięcia. Skomentuj jak zmieniają się te miary wraz ze wzrostem p^*.