

Zaawansowana Ekonometria

Pawel Struski

Uniwersytet Warszawski

18 maja 2026

Dane panelowe – wprowadzenie

Panel = obserwacje tych samych jednostek $i = 1, \dots, N$ w wielu okresach $t = 1, \dots, T$.

$$y_{it}, \quad X_{it} \quad i = 1, \dots, N; \quad t = 1, \dots, T$$

Dwa wymiary zmienności:

- *between* – różnice między jednostkami (przekrój),
- *within* – zmiany w czasie dla danej jednostki (szereg czasowy).

Typowy zapis modelu:

$$y_{it} = X_{it}\beta + u_i + \varepsilon_{it}$$

- u_i – efekt indywidualny, stały w czasie (*ability*, geny, kultura),
- ε_{it} – szok idiosynkratyczny, zmienny w czasie i jednostce.

Dlaczego panel jest cenny?

- **Kontrola nieobserwowalnej heterogeniczności** – u_i wyciagane przez FE/first-differences. Nawet jeśli u_i jest skorelowane z X_{it} , dostajemy spójne $\hat{\beta}$.
- **Dynamika na poziomie mikro** – przejścia, persystencja (np. długotrwałe ubóstwo).
- **Większa moc statystyczna** – NT obserwacji zamiast N lub T .

Zadanie 1A – określ typ danych

Określ, z jakim typem danych mamy styczność:

- ❶ Ciąg obserwacji z lat 1995–2010 w Polsce: zagregowane dochody gospodarstw domowych, wartość produkcji żywności oraz indeks cen.
- ❷ Próba losowa z roku 2003 z badania gospodarstw domowych: dochody, wydatki na żywność, indeks cen dla Polski.
- ❸ Próba z badania budżetów gospodarstw domowych – niezależne próby losowe z lat 2000, 2005, 2010.
- ❹ Próba z badań budżetów gospodarstw domowych z lat 2000–2005, pięć próbek (po jednej na rok) dotyczących *tych samych* gospodarstw.

Zadanie 1B – zastosowania

Który ze zbiorów wykorzystamy w badaniu:

- **Zróźnicowania wydatków gospodarstw domowych**
⇒ pojedynczy przekrój (2) – wystarczy do oszacowania rozkładu wydatków między gospodarstwami w danym momencie.
- **Zmian w strukturze wydatków**
⇒ pooled cross-section (3) lub panel (4) – potrzebny wymiar czasowy z *poziomu mikro*.
- **Długotrwałego ubóstwa i jego wpływu na wydatki na żywność**
⇒ *tylko* panel (4) – ubóstwo długotrwałe to cecha *jednostki w czasie*.

Zadanie 2 Dane

Tabela z komendy *xtdescribe* w Stata.

Freq.	Percent	Cum.	Pattern
13674	83.86	83.86	11..11
952	5.84	89.70	.1..11
738	4.53	94.22	11
346	2.12	96.34	11....
232	1.42	97.77	1
142	0.87	98.64	11..1.
122	0.75	99.39	1.....
38	0.23	99.62	.1....
31	0.19	99.81	1.
15	0.09	99.90	.1..1.
7	0.04	99.94	11...1
5	0.03	99.98	1...11
4	0.02	100.00	.1...1
16306	100.00		XX..XX

Zadanie 2A – czy panel jest zbilansowany?

Definicja: Panel zbilansowany to taki, w którym każda jednostka obserwowana jest we *wszystkich* okresach (wzorzec „111111”).

Zadanie 2B – attrition rate

Jaki procent obserwacji utracono prawdopodobnie w związku z wycieraniem się panelu? Wzorce charakterystyczne dla attrition to te kończące się „.” (po wejściu do panelu respondent przestaje odpowiadać przed końcem badania):

Pattern	Percent
11....	2.12
11..1.	0.87
1.....	0.75
.1....	0.23
....1.	0.19
.1..1.	0.09
Razem	4.25%

Zadanie 2C – kiedy niezbilansowanie jest problemem?

Niezbilansowanie samo w sobie nie jest problemem – estymatory FE/RE radzą sobie z różną liczbą obserwacji na jednostkę.

Problem pojawia się, gdy attrition jest skorelowane z ε_{it} – tzn. gdy mechanizm wypadania z próby jest *niełosowy* (selection on unobservables).

Przykłady:

- Badanie dochodu, a najbiedniejsi/najbogatsi częściej rezygnują z udziału.
- Badanie zdrowia, a osoby ciężko chore wypadają (np. umierają).

Test: regresja $\Pr(\text{attrition})$ na obserwowalnych charakterystykach. Korekty: ważenie odwrotnością prawdopodobieństwa pozostania (IPW), Heckman selection model.

Zadanie 3 – przykładowy model efektów nieobserwowalnych

Dane panelowe (te same osoby w 1975 i 1981).

$$\begin{aligned}\text{minutysnu}_{it} = & \beta_0 + \delta_0 d81_t + \beta_1 \text{minutypracy}_{it} \\ & + \beta_2 \text{wykształcenie}_{it} + \beta_3 \text{dzieci}_{it} + u_i + \varepsilon_{it}\end{aligned}$$

3A. Interpretacja składowych:

- β_0 – średni poziom snu w roku 1975 dla osoby referencyjnej (z $u_i = 0$, zero pracy, zero edukacji, brak małych dzieci).
- δ_0 – przesunięcie stałej w 1981 r.; agregatowa zmiana norm snu między 1975 a 1981, po kontroli pozostałych zmiennych ($d81 = 1$ dla obserwacji z 1981).
- β_1 – o ile minut mniej (lub więcej) śpi osoba pracująca o jedną minutę dłużej, *ceteris paribus*.

Zadanie 3A – c.d

- β_2 – efekt dodatkowego roku edukacji na sen
- β_3 – efekt posiadania dziecka poniżej 6 lat
- u_i – **efekt nieobserwowalny indywidualny** (chronotyp, zdrowie, geny).
Niezmienny w czasie dla danej osoby.
- ε_{it} – idiosynkratyczny błąd losowy, zmienny w czasie i osobie.

Kluczowe pytanie metodologiczne: czy u_i jest skorelowane z regresorami?

- Jeśli **tak**, musimy użyć estymatora **Fixed Effects (FE)**.
- Jeśli **nie** (silne założenie) $\Rightarrow$, lepiej użyć estymatora Random Effects (RE), ponieważ jest efektywniejszy niż FE.

Używamy testu Hausman'a żeby to sprawdzić (H_0 : RE zgodny).

Więcej na ten temat, na następnych zajęciach.